Classificação no dataset Iris: estatísticas, PCA e K-NN

Gustavo Jakobi GRR20221253 Bruno Crestani GRR20221240

Código: `https://github.com/GJakobi/iris-knn-pca`

Dados. UCI Iris: 150 amostras, 4 variáveis (cm) e 3 classes balanceadas (50 amostras cada).

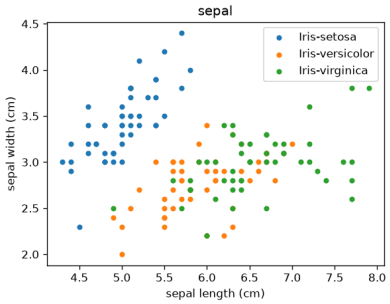
1. Estatísticas (média / desvio / moda).

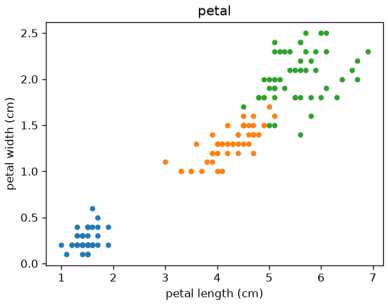
	Geral	Setosa	Versicolor	Virginica
sepal_length	5,84/0,83/5,0	5,01/0,35/5,0	5,94/0,52/5,5	6,59/0,64/6,3
sepal_width	3,05/0,43/3,0	3,42/0,38/3,4	2,77/0,31/3,0	2,97/0,32/3,0
petal_length	3,76/1,76/1,5	1,46/0,17/1,5	4,26/0,47/4,5	5,55/0,55/5,1
petal_width	1,20/0,76/0,2	0,24/0,11/0,2	1,33/0,20/1,3	2,03/0,28/1,8

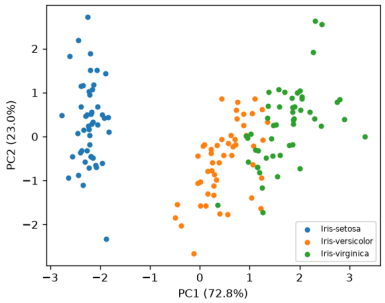
2. Comprimento × largura (correlação de Pearson).

	Setosa	Versicolor	Virginica
Sépala	0,75	0,53	0,46
Pétala	0,31	0,79	0,32

A sépala tem correlação positiva nas três classes. Na pétala, só a versicolor tem correlação forte. A setosa forma um grupo separado nos dois gráficos.







3. Distribuição das classes. As variáveis de pétala separam melhor as classes. A setosa não se sobrepõe às outras duas. Versicolor e virginica se sobrepõem pouco. Na sépala, as três classes se sobrepõem bastante.

4. PCA (dados padronizados). PC1 explica 72,8% da variância e PC2 explica 23,0%. Juntas, elas explicam 95,8%. PC1 soma `sepal_length`, `petal_length` e `petal_width` (pesos 0,52, 0,58 e 0,57): ela mede o "tamanho da flor". PC2 é quase só `sepal_width` (peso 0,93). No plano PC1×PC2, a setosa fica isolada. Versicolor e virginica se tocam em uma região pequena.

5. K-NN. Divisão 80% treino (120) e 20% teste (30), com `train_test_split` (`random_state=42`). Distância euclidiana, variáveis padronizadas com média e desvio do treino.

Entrada	k	Acurácia no teste
4 variáveis	1, 3, 5, 7, 9, 11, 15	1,000 (todos)
PC1 + PC2	1 / 5 / 11	0,867 / 0,933 / 0,900

Com as 4 variáveis, a matriz de confusão é diagonal: nenhum erro (10 setosa, 9 versicolor, 11 virginica). Com PC1 e PC2, os erros ocorrem entre versicolor e virginica.

Conclusões.

- A setosa é linearmente separável das outras duas classes. Só versicolor e virginica podem ser confundidas.
- O K-NN acerta 100% no teste para todos os k testados.
- O teste tem só 30 amostras. Um erro muda a acurácia em 3,3 pontos. Por isso, 100% não prova que o modelo é perfeito.
- O PCA reduz de 4 para 2 dimensões e perde cerca de 4% da variância. Essa perda custa de 7 a 13 pontos de acurácia.